Práctica: Resolución y Visualización de Problemas de Probabilidad y Distribuciones en R

Azuara Yáñez Cecil Quimey
Universidad de Guanajuato
438908
León, Guanajuato, México
cq.azuarayanez@ugto.mx

Castro Gutiérrez Héctor
Universidad de Guanajuato
286643
Irapuato, Guanajuato, México
h.castrogutierrez@ugto.mx

García Briones Juan Pablo
Universidad de Guanajuato
617368
Salamanca, Guanajuato, México
jp.garciabriones@ugto.mx

León Amaya Juan Pablo
Universidad de Guanajuato
318588
Guanajuato, Guanajuato, México
jp.leonamaya@ugto.mx

Rojas Mata Diego Moisés
Universidad de Guanajuato
540410
Dolores Hidalgo, Guanajuato, México
dm.rojasmata@ugto.mx

Villafaña Vallejo Giovanni
Universidad de Guanajuato
286355
Irapuato, Guanajuato, México
g.villafanavallejo@ugto.mx

Profesor
Dr. Juan José Cárdenas Cornejo
Universidad de Guanajuato
División de Ingenierías
Campus Irapuato-Salamanca
Probabilidad
jj.cardenasc@ugto.mx

***Resumen*—Esta práctica está enfocada a la implementación computacional en R para la resolución de problemas probabilísticos. Se abordan tópicos que van desde la generación de espacios muestrales, técnicas de conteo y probabilidad condicional, hasta el modelado de variables aleatorias mediante distribuciones discretas y continuas. También se integran cálculos numéricos con la generación estructurada de Data Frames y la visualización de densidades y probabilidades acumuladas mediante la librería ggplot2.**

I. Introducción

La teoría de la **probabilidad** proporciona las bases matemáticas para modelar la incertidumbre en la vida diaria. El pasar del cálculo manual al uso de entornos computacionales como R nos permite no solo calcular probabilidades teóricas exactas, sino simular escenarios estocásticos de forma empírica y manipular grandes volúmenes de datos.

El objetivo general de esta práctica es implementar soluciones computacionales en R para la resolución de problemas de probabilidad y estadística, integrando técnicas de simulación, análisis de distribuciones y generación de visualizaciones.

- Generar espacios muestrales complejos utilizando herramientas algorítmicas computacionales.
- Aplicar técnicas de conteo, como las permutaciones y combinaciones, a problemas de fiabilidad y selección.
- Contrastar la probabilidad teórica con la empírica en variables aleatorias discretas y continuas.
- Visualizar funciones de masa de probabilidad (fmp) y funciones de densidad mediante el uso de gráficos `ggplot2`.

El uso de herramientas computacionales resulta indispensable en el análisis probabilístico moderno, ya que permite automatizar cálculos complejos, validar resultados teóricos mediante simulaciones y representar gráficamente el comportamiento de diferentes distribuciones estadísticas. En particular, el lenguaje R ofrece un amplio conjunto de funciones especializadas para el estudio de fenómenos aleatorios, facilitando tanto el análisis cuantitativo como la visualización de resultados.

El presente documento detalla la estructura del código implementado, los resultados analíticos obtenidos y la discusión del comportamiento asintótico y de asimetría observado en las simulaciones.

II. Metodología

Para la resolución de los problemas planteados, se desarrolló un proyecto computacional modular en el IDE `RStudio`. El diseño arquitectónico del proyecto se basó en el uso de un ancla `.Rproj`, lo que permitió la referenciación mediante rutas relativas hacia las subcarpetas de *Data*, *Funciones* y *Resultados*. Todo el código fue orquestado por un script controlador (`main.R`) que llamó a módulos específicos mediante la función `source()`, aislando la lógica de variables discretas, continuas y de probabilidad clásica.

Para la exploración de los espacios muestrales clásicos se empleó la función `expand.grid()`, lo que permitió realizar el producto cartesiano de los vectores base (e.g., monedas y dados) y obtener la cardinalidad teórica $n(S)$. El filtrado de casos favorables $n(A)$ se realizó mediante operaciones lógicas vectorizadas con la función `subset()` y el operador de coincidencia `in`. En los problemas de técnicas de conteo, se priorizó el uso de funciones nativas de R como `choose()` y `factorial()` para optimizar los cálculos combinatorios.

Finalmente, para asegurar el rigor científico y la reproducibilidad total de los experimentos estocásticos, se fijó una semilla pseudoaleatoria mediante el comando `set.seed(123)` al inicio del script maestro. Las exportaciones de tablas se realizaron mediante `write.csv()` y los gráficos fueron renderizados con el paquete `ggplot2`.

II-A. Fundamento matemático

Para la resolución de los ejercicios se emplearon principios de probabilidad clásica, probabilidad condicional y distribuciones de probabilidad discretas y continuas. Entre las expresiones matemáticas utilizadas destacan:

- Probabilidad clásica: Es un experimento con un número finito de resultados, todos igualmente probables basada en el número de casos favorables respecto al total de casos.

$$P(A) = \frac{n(A)}{n(S)}$$

  Donde:
  $n(A)$: No. de casos probables
  $n(S)$: Total de casos

- Combinaciones: Es una selección de objetos, sin importar el orden; solo se interesa que objetos elijan.

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}$$

  Donde:
  n: Número total de elementos disponibles
  r: Número de elementos que se van a seleccionar

- Permutaciones: Es un arreglo ordenado de un conjunto de objetos. Se basan en el principio fundamental del conteo y en el concepto de que el orden importa.

$$P(n,r) = \frac{n!}{(n-r)!}$$

  Donde:
  n: Número total de elementos disponibles
  r: Número de elementos que se van a seleccionar

- Probabilidad condicional: Es una medida que cuantifica la probabilidad de que ocurra un evento A, dado que previamente se sabe que ha ocurrido otro evento B. Este concepto permite actualizar la probabilidad de un evento cuando se dispone de información adicional sobre el experimento aleatorio.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Donde:

- $P(A|B)$: Probabilidad de que ocurra el evento A dado que ocurrió B.
- $P(A \cap B)$: Probabilidad de que ocurran simultáneamente los eventos A y B.
- $P(B)$: Probabilidad del evento B, con $P(B) > 0$.

- Teorema de Bayes: Permite pasar de probabilidad de Ün efecto dado una causa"$P(E|C)$ a la de una çausa dado un efecto"$P(C|E)$.

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^{n} P(B|A_j)P(A_j)}$$

Donde:

- $P(A_i|B)$: Probabilidad posterior de que haya ocurrido la causa A_i dado que se observó el evento B.
- $P(B|A_i)$: Probabilidad de observar el evento B suponiendo que ocurrió la causa A_i.
- $P(A_i)$: Probabilidad previa de la causa A_i.
- $\sum_{j=1}^{n} P(B|A_j)P(A_j)$: probabilidad total de observar el evento B.
- n: Número total de causas o hipótesis mutuamente excluyentes consideradas.

- Distribución Binomial: Cuenta el número de éxito (X) en X ensayos de Bernoulli que son independientes e idénticos.

$$P(X = x) = \binom{n}{x} p^x (1-p)^{n-x}$$

Donde:
X: Variable aleatoria binomial.
x: Número específico de éxitos deseado.
n: Número total de ensayos realizados.
p: Probabilidad de éxito en cada ensayo.
$1-p$: Probabilidad de fracaso en cada ensayo.
$\binom{n}{x}$: Número de formas de obtener exactamente x éxitos en n ensayos.

- Distribución de Poisson: Modela el número de veces que ocurre un evento puntual a lo largo de un intervalo continuo (tiempo, longitud, área o volumen).

$$P(X = x) = \frac{e^{-\lambda}\lambda^x}{x!}$$

Donde:
λ: Tasa promedio de ocurrencia por unidad de medida
X: No. de eventos
e: Constante de euler

- Distribución Normal: Es la distribución más trascendental debido al **teorema del límite central**, el cual establece que la suma o promedio de un gran número de variables aleatorias independientes tiende a seguir una distribución normal.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Donde:
x: Valor de la variable aleatoria
μ: Media de la distribución
σ: Desviación estándar
σ^2: Varianza de la distribución

III. Resultados

III-A. Espacios Muestrales y Técnicas de Conteo

En esta sección se presentan los resultados obtenidos mediante la implementación de los algoritmos desarrollados en R para la resolución de los ejercicios planteados. Se incluyen cálculos de probabilidad clásica, probabilidad condicional, simulaciones empíricas y el análisis de diversas distribuciones discretas y continuas. Los resultados fueron organizados en tablas y visualizaciones gráficas con el objetivo de facilitar su interpretación y comparar el comportamiento teórico con los valores obtenidos mediante simulación computacional.

A continuación, se presentan los resultados analíticos y computacionales para los primeros 8 ejercicios planteados, abordando fundamentos de cardinalidad y conteo.

- **Ejercicio 1 (Moneda y Dado):** Un experimento consiste en lanzar una moneda y luego un dado de 6 caras. Genera el espacio muestral completo y determina la probabilidad de obtener Cara 2 un numero par.

  Resultado: Se construyó un espacio muestral de cardinalidad $n(S) = 12$. La probabilidad de obtener Cara y un número par $\{2, 4, 6\}$ se calculó filtrando el Data Frame, resultando en 3 casos favorables.

$$P(A) = \frac{3}{12} = 0{,}25$$

- **Ejercicio 2 (Suma de Tres Dados):** Se lanzan tres dados de 6 caras. Genera el espacio muestral e identifica los casos donde la suma total es exactamente 10.

  Resultado: El espacio muestral computacional arrojó $6^3 = 216$ combinaciones. Al aplicar la función `rowSums()` y filtrar los eventos cuya suma exacta es 10, se obtuvieron 27 escenarios favorables.

$$P(\text{Suma} = 10) = \frac{27}{216} = 0{,}125$$

- **Ejercicio 3 (Esferas con Reemplazo):** Una caja contiene 4 esferas negras, 3 blancas y 2 rojas. Genera el espacio muestral de extraer 3 esferas con reemplazo y calcula cuantos puntos muestrales posibles existen en total.

  Resultado: Para una urna virtual con 4 esferas negras, 3 blancas y 2 rojas (9 en total), se programaron 3 extracciones con reemplazo. El total de puntos muestrales generados por `expand.grid()` fue:

$$n(S) = 9 \times 9 \times 9 = 729 \text{ puntos muestrales}$$

- **Ejercicio 4 (Figuras en una Baraja):** Se extrae una carta de una baraja estandar de 52 cartas. Genera el espacio muestral y calcula la probabilidad de obtener una figura (J, Q, K) de cualquier palo.

  Resultado: Se cruzaron computacionalmente 4 palos con 13 valores posibles, confirmando una cardinalidad de 52. Los casos favorables para obtener una figura (J, Q, K) fueron 12.

$$P(\text{Figura}) = \frac{12}{52} \approx 0{,}2307$$

- **Ejercicio 5 (Medallas en Atletismo):** En una carrera de atletismo participan 8 corredores. ¿De cuantas formas distintas pueden repartirse las medallas de oro, plata y bronce?

  Resultado: Dado que el orden de llegada importa (Oro, Plata, Bronce), se utilizó una permutación de 8 corredores tomados de 3 en 3.

$$P_3^8 = \frac{8!}{(8-3)!} = 336 \text{ formas posibles}$$

- **Ejercicio 6 (Selección de Analistas):** Un equipo de proyecto requiere 5 analistas elegidos de un grupo de 12 candidatos disponibles. ¿Cuantas combinaciones de equipos diferentes se pueden formar?

  Resultado: Como el orden de selección para el equipo no es relevante, se utilizó la función nativa `choose(12, 5)`.

$$C_5^{12} = \binom{12}{5} = \frac{12!}{5!(12-5)!} = 792 \text{ grupos distintos}$$

- **Ejercicio 7 (Canicas que no son verdes):** En una bolsa hay 6 canicas azules, 4 amarillas y 5 verdes. Si se saca una al azar, ¿cual es la probabilidad de que no sea verde?

  Resultado: De un total de 15 canicas (6 Azules, 4 Amarillas, 5 Verdes), los casos favorables (Azul + Amarilla) son 10.

$$P(\text{No Verde}) = \frac{10}{15} \approx 0{,}6667$$

- **Ejercicio 8 (Tres Cruces en Cuatro Lanzamientos):** Calcula la probabilidad clasica de que, al lanzar una moneda 4 veces de forma independiente, se obtengan exactamente 3 Cruces.

  Resultado: Mediante el principio combinatorio, se calcularon las formas de acomodar 3 cruces en 4 espacios disponibles sobre el espacio muestral total de $2^4 = 16$.

$$P(3 \text{ Cruces}) = \frac{\binom{4}{3}}{16} = \frac{4}{16} = 0{,}25$$

III-B. Probabilidad Condicional y Teorema de Bayes

A continuación, se presentan los resultados obtenidos para los ejercicios 9 al 12, relacionados con la probabilidad condicional y el Teorema de Bayes. Estos problemas permitieron estudiar la dependencia entre eventos aleatorios y la actualización de probabilidades a partir de información adicional, empleando tanto procedimientos analíticos como herramientas computacionales implementadas en R.

- **Ejercicio 9 (Suma de dados = 7):** Se lanzan dos dados. Sabiendo que al menos uno de los dados muestra un 4, ¿cuál es la probabilidad de que la suma de ambos sea 7?

  Resultado: Usando la formula de probabilidad condicional $P(A|B) = \frac{P(A \cap B)}{P(B)}$ queremos saber los reultados que cumplen con B (Casos con al menos un 4) que son $(4,1), (4,2), (4,3), (4,4), (4,5), (4,6)$ y $(1,4), (2,4), (3,4), (5,4), (6,4)$ por lo tanto $P(B) = 11$, los únicos resultado que satisfacen A y B es $(4,3), (3,4)$ por lo que aplicando a la fórmula

$$P(A|B) = \frac{2}{11} = 0{,}1818 \approx 18{,}18\,\%$$

- **Ejercicio 10 (Palo de espadas):** De una baraja de 52 cartas se saca una al azar. Si la carta extraida resulta ser una figura (J, Q, K), ¿cual es la probabilidad de que sea del palo de espadas?

  Resultado: Usando la formula de probabilidad condicional $P(A|B) = \frac{P(A \cap B)}{P(B)}$ queremos saber la probabilidad de que nuestra carta sea de espadas una vez que sabemos que la carta es una figura. En la baraja existen 4 palos y cada palo contiene tres fijuras entre rey, reina y jota $(4 \cdot 3)$ por lo tanto $P(B) = \frac{12}{52}$ y $P(A \cap B) = \frac{3}{52}$ aplicando a la formula

$$P(Espadas|Figuras) = \frac{\frac{3}{52}}{\frac{12}{52}} = \frac{1}{4} = 0{,}25 \approx 25\,\%$$

- **Ejercicio 11 (Defectos de pantalla):** En un lote de 20 telefonos, 5 tienen defectos de pantalla. Se extraen 2 al azar sin reemplazo. Si el primero resulto defectuoso, ¿cuál es la probabilidad de que el segundo tambien lo sea?

  Resultado: Usando la formula de probabilidad condicional $P(A|B) = \frac{P(A \cap B)}{P(B)}$ queremos saber la probabilidad de sacar otro celular defecruoso dado que ya sacamos uno defectuoso, al saber que el primer teléfono fue defectuososo $P(B) = 20 - 1 = 19$ y $P(A \cap B) = 5 - 1 = 4$ por lo tanto:

$$P(A|B) = \frac{4}{19} = 0{,}2105 \approx 21{,}05\,\%$$

- **Ejercicio 12 (Piezas defectuosas del proveedor C):** Tres proveedores A, B y C suministran el 50 %, 30 % y 20 % de las piezas de una fabrica, respectivamente. El porcentaje de piezas defectuosas de cada proveedor es 1 %, 2 % y 5 %. Si un inspector encuentra una pieza defectuosa, ¿cual es la probabilidad de que provenga del proveedor C?

  Resultado: Se desea determinar la probabilidad de que una pieza defectuosa provenga del proveedor C. Por lo que el teorema de Bayes quedaria tal que:

  $P(C|D) = \frac{P(D|C)P(C)}{P(D)}$
  Donde:
  $P(D) = (0{,}50)(0{,}01) + (0{,}30)(0{,}02) + (0{,}20)(0{,}05)$
  entonces $P(D) = 0{,}021$
  ahora aplicando a la formula final:

  $$P(C|D) = \frac{(0{,}20)(0{,}05)}{0{,}021} = 0{,}4762 \approx 47{,}62\,\%$$

III-C. Probabilidad Empírica y Distribuciones Discretas

A continuación, se presentan los resultados correspondientes a los ejercicios 13 al 18, enfocados en la probabilidad empírica y el análisis de distribuciones discretas. Mediante simulaciones computacionales y el uso de funciones estadísticas especializadas de R, se compararon probabilidades teóricas con frecuencias observadas experimentalmente. Asimismo, se estudiaron diferentes modelos probabilísticos discretos, tales como las distribuciones Uniforme Discreta, Binomial, Poisson, Hipergeométrica, Geométrica y Binomial Negativa, evaluando su comportamiento mediante tablas de datos y representaciones gráficas.

- **Ejercicio 13 (Carta con reemplazo):** Simula la extraccion de una carta de un mazo de 52 cartas 5,000 veces (con reemplazo). ¿Cual es la probabilidad empírica de obtener un Corazon? Genera la muestra y grafica las frecuencias relativas por palo.

  Resultado: **(Uniforme Discreta / Empírica)** Se modela la extracción de cada carta de la baraja como un experimento donde la variable aleatoria X describe el palo obtenido. Al tratarse de un mazo estándar de 52 cartas dividido equitativamente en 4 palos (Corazones, Diamantes, Picas y Tréboles), cada palo posee $K = 13$ cartas.

  Dado que el muestreo se realiza con reemplazo ($n_{sim} = 5000$), la probabilidad teórica se mantiene constante para cada ensayo bajo una distribución uniforme discreta con $P(\text{Palo}) = \frac{13}{52} = 0{,}25$.

  Aplicando la función `sample(palos, size = 5000, replace = TRUE)` y procesando las frecuencias con `table()` en R, se obtiene la probabilidad basada en la frecuencia relativa observada:

  $$P(X = \text{Corazones}) = \frac{\text{Frec. corazon}}{n_{sim}} \approx 0{,}2500$$

- **Ejercicio 14 (15 preguntas y una opción correcta):** Un test de opcion múltiple tiene 15 preguntas, cada una con 4 opciones de respuesta (solo una correcta). Si un estudiante responde completamente al azar, ¿cual es la probabilidad de que acierte exactamente 5 preguntas? Simula 10,000 examenes para comprobarlo.

  Resultado: **(Binomial)** Se modela el experimento mediante una variable aleatoria discreta $X \sim \text{Binomial}(n = 15, p = 0{,}25)$, donde n representa el número total de preguntas independientes (ensayos de Bernoulli) y $p = \frac{1}{4} = 0{,}25$ denota la probabilidad de éxito al responder una pregunta correctamente de forma aleatoria.

  Al tratarse de eventos con reemplazo conceptual y probabilidades constantes, se calcula la probabilidad exacta evaluando la función de masa de probabilidad binomial. Apli-

cando la función `dbinom(5, size=15, prob=0.25)` y simulando la ejecución de la muestra mediante `rbinom(10000, size=15, prob=0.25)` en R, se contrasta la solución analítica con la empírica:

$$P(X=5) = \binom{15}{5}(0{,}25)^5(0{,}75)^{10} \approx 0{,}165146$$

- **Ejercicio 15 (Solicitudes por segundo):** Un servidor web recibe, en promedio, λ = 12 solicitudes por segundo. ¿Cual es la probabilidad de que reciba exactamente 10 solicitudes en un segundo determinado? Simula 5,000 de estos escenarios.

  Resultado: **(Poisson)** Se modela el número de ocurrencias de un evento discreto en un intervalo continuo de tiempo mediante una variable aleatoria $X \sim \text{Poisson}(\lambda = 12)$, donde λ representa la tasa promedio de solicitudes por segundo. Dado que las solicitudes ocurren de manera independiente a una tasa constante, se evalúa la función de masa de probabilidad de Poisson para determinar la probabilidad exacta de un valor puntual.

  Utilizando las funciones `dpois(10, lambda=12)` para el caso exacto, `ppois(7, lambda=12, lower.tail=FALSE)` para la probabilidad acumulada complementaria, y simulando los escenarios mediante `rpois(5000, lambda=12)` en R, se contrastan los resultados analíticos y empíricos:

$$P(X=10) = \frac{e^{-12}\cdot 12^{10}}{10!} \approx 0{,}104837$$

  Adicionalmente, la probabilidad de recibir más de 7 solicitudes en un segundo se calcula de forma exacta como:

$$P(X>7) = 1 - \sum_{k=0}^{7} \frac{e^{-12}\cdot 12^k}{k!} \approx 0{,}910521$$

- **Ejercicio 16 (Componentes eléctricos defectuosos):** Un lote de 40 componentes electrónicos contiene 8 unidades defectuosas. Si un ingeniero selecciona una muestra de 6 componentes al azar sin reemplazo, ¿cuál es la probabilidad de encontrar exactamente 1 componente defectuoso?

  Resultado: **(Hipergeométrica)** Se modela el experimento como una variable aleatoria $X \sim \text{Hipergeom}(N=40,\ K=8,\ n=6)$, donde N es el tamaño del lote, K los defectuosos y n el tamaño de la muestra. Al ser una extracción *sin reemplazo*, no aplica una distribución Binomial. Aplicando la función `dhyper(x=1, m=8, n=32, k=6)` en R:

$$P(X=1) = \frac{\binom{8}{1}\binom{32}{5}}{\binom{40}{6}} \approx 0{,}4197$$

  Por lo tanto, existe una probabilidad de aproximadamente **41.97 %** de obtener exactamente un componente defectuoso en la muestra. Este valor es consistente con el valor esperado $E[X] = n \cdot K/N = 1{,}2$.

- **Ejercicio 17 (Tiros libres de baloncesto):** Un jugador de baloncesto tiene un 75 % de probabilidad de encestar un tiro libre. ¿Cuál es la probabilidad de que falle exactamente 2 tiros antes de lograr encestar su primer tiro libre (éxito)?

  Resultado: **(Geométrica)** Sea X el número de fracasos antes del primer éxito, $X \sim \text{Geom}(p = 0{,}75)$. Aplicando `dgeom()` en R:

$$P(X=2) = (1-p)^2 \cdot p = (0{,}25)^2(0{,}75) \approx 0{,}0469$$

  Existe un **4.69 %** de probabilidad de fallar exactamente 2 tiros antes de encestar. El valor es bajo porque $p = 0{,}75$ es alta, lo que hace que el primer enceste ocurra típicamente en los primeros intentos.

- **Ejercicio 18 (Inspector de calidad):** Un inspector de calidad revisa productos en una banda transportadora. La probabilidad de encontrar un producto defectuoso es del 10 %. ¿Cuál es la probabilidad de que deba revisar exactamente 15 productos para encontrar el tercer producto defectuoso?

Resultado: **(Binomial Negativa)** Se busca el r-ésimo éxito ($r = 3$) con probabilidad $p = 0{,}10$. Como se revisan 15 productos en total para encontrar 3 defectuosos, el número de fracasos previos es $x = 15 - 3 = 12$. Con $X \sim \text{BinNeg}(r = 3,\, p = 0{,}10)$:

$$P(X = 12) = \binom{14}{12}(0{,}9)^{12}(0{,}1)^3 \approx 0{,}0257$$

Por lo tanto, hay un **2.57 %** de probabilidad de que se requieran exactamente 15 inspecciones para encontrar el tercer defectuoso. Este valor es bajo porque el valor esperado de intentos es $r/p = 30$, lo que indica que se necesitarían en promedio 30 revisiones para hallar 3 defectuosos.

III-D. Distribuciones Continuas

A continuación, se presentan los resultados obtenidos para los ejercicios 19 al 24, enfocados en el estudio de distribuciones continuas de probabilidad. Mediante el uso de funciones estadísticas de R, se calcularon probabilidades, cuantiles y funciones de densidad asociadas a las distribuciones Normal, Uniforme Continua, Exponencial, Gamma, Weibull y Log-Normal. Asimismo, se generaron representaciones gráficas que permitieron analizar visualmente el comportamiento de cada modelo probabilístico y comprender la influencia de sus parámetros sobre la forma de las distribuciones.

- **Ejercicio 19 (Peso de componente electrónico):** El peso de un componente sigue una distribución normal con $\mu = 50$ g y $\sigma = 2$ g. ¿Cuál es la probabilidad de que un componente pese entre 48 g y 52 g? Calcula también el percentil 90.

  Resultado: **(Normal)** Sea $X \sim \mathcal{N}(50, 2)$.
  Pregunta A: Con `pnorm()` se obtiene:

  $$P(48 \leqslant X \leqslant 52) = F(52) - F(48) \approx 0{,}6827$$

  El **68.27 %** de los componentes pesa entre 48 g y 52 g, coincidiendo con la regla 68-95-99.7 al ser el intervalo $\mu \pm \sigma$.

  Pregunta B: El percentil 90 con `qnorm(0.90, 50, 2)`:

  $$x_{0{,}90} = \mu + z_{0{,}90}\sigma \approx 52{,}56 \text{ g}$$

  Es decir, el **90 %** de los componentes pesa **52.56 g o menos**.

- **Ejercicio 20 (Peticiones en milisegundos):** El tiempo de espera para que un servidor procese una peticion se distribuye uniformemente entre 5 y 15 milisegundos. ¿Cual es la probabilidad de que una peticion tarde mas de 12 milisegundos?

  Resultado: **(Uniforme continua)** Sea $X \sim U(5, 15)$. Aplicando la fórmula clásica de la cola derecha:

  $$P(X > 12) = \frac{b - x}{b - a} = \frac{15 - 12}{15 - 5}$$

  $$P(X > 12) = \frac{3}{10} = 0{,}3000$$

  Existe un **30.00 %** de probabilidad de que una petición tarde más de 12 ms en procesarse.

- **Ejercicio 21 (Tiempo informático):** El tiempo entre fallas de un sistema informatico sigue una distribucion exponencial con una tasa de λ = 0,1 fallas por día. ¿Cual es la probabilidad de que el sistema opere por mas de 15 días sin presentar fallas?

  Resultado: **(Exponencial)** Sea $X \sim \text{Exp}(\lambda = 0{,}1)$. Usando la fórmula:

  $$P(X > 15) = e^{-\lambda \cdot x} = e^{-0{,}1 \cdot 15}$$

  $$P(X > 15) = e^{-1{,}5} \approx 0{,}2231$$

  El **22.31 %** de los sistemas logrará operar más de 15 días continuos sin reportar fallas.

- **Ejercicio 22 (Compilación de software):** El tiempo necesario para compilar un software complejo sigue una distribucion Gamma con parametro de forma α = 3 y escala β = 2 minutos. ¿Cual es la probabilidad de que la compilacion termine en menos de 5 minutos?

Resultado: **(Gamma)** Sea $X \sim \text{Gamma}(3, 1{,}5)$. Como $\alpha = 3$ es un número entero, usamos la fórmula:

$$P(X < 5) = 1 - \sum_{k=0}^{2} \frac{(\frac{x}{\beta})^k \cdot e^{-\frac{x}{\beta}}}{k!}$$

$$P(X < 5) = 1 - e^{-\frac{5}{1{,}5}} \left[1 + \frac{5}{1{,}5} + \frac{(\frac{5}{1{,}5})^2}{2} \right] \approx 0{,}4562$$

Hay un **45.62 %** de probabilidad de que la compilación termine antes de los 5 minutos.

- **Ejercicio 23 (Bateria de un sensor):** La vida util de la batería de un sensor IoT se modela con una distribucion de Weibull con forma k = 1,5 y escala λ = 500 horas. Calcula la probabilidad de que la bater´ıa dure mas de 600 horas.

  Resultado: **(Weibull)** Sea $X \sim \text{Weibull}(1{,}5, 500)$. Aplicando la fórmula directa:

  $$P(X > 600) = e^{-\left(\frac{x}{\lambda}\right)^k} = e^{-\left(\frac{600}{500}\right)^{1{,}5}}$$

  $$P(X > 600) = e^{-(1{,}2)^{1{,}5}} \approx 0{,}2686$$

  El **26.86 %** de las baterías analizadas superará las 600 horas de uso continuo.

- **Ejercicio 24 (Bateria de un sensor):** El trafico de red en un servidor (en GB) sigue una distribucion Log-Normal con μlog = 3 y σlog = 0,5. Determina la probabilidad de que el trafico en un día particular sea inferior a 15 GB.

  Resultado: **(LogNormal)** Sea $X \sim \text{Lognormal}(3, 0{,}5)$. Aplicando la fórmula de transformación a la variable estandarizada Z:

  $$Z = \frac{\ln(x) - \mu}{\sigma} = \frac{\ln(15) - 3}{0{,}5}$$

  $$Z = \frac{2{,}7080 - 3}{0{,}5} = -0{,}5839 \approx -0{,}58$$

  Buscamos el valor en la tabla de la Normal Estándar para un valor de Z negativo, aplicamos la propiedad de simetría restando de 1 el valor del extremo positivo de la tabla ($Z = 0{,}58 \rightarrow 0{,}7190$):

  $$P(X < 15) = P(Z < -0{,}58) = 1 - P(Z < 0{,}58)$$

  $$P(X < 15) = 1 - 0{,}7190 = 0{,}2810$$

  El **28.10 %** del tráfico registrado en el nodo será inferior a los 15 GB.

IV. Analisis de data frames y graficas

La transposición de los modelos probabilísticos teóricos a un entorno computacional requiere de estructuras de datos capaces de almacenar, indexar y manipular grandes volúmenes de información de manera eficiente. En el lenguaje R, los Data Frames se erigen como la herramienta arquitectónica fundamental para este propósito, al permitir la organización de variables vectorizadas en una matriz bidimensional de filas y columnas.

El objetivo de este apartado es analizar la conformación y el comportamiento de las tablas de datos generadas a lo largo de la práctica, las cuales consolidan tanto las frecuencias observadas mediante simulaciones estocásticas (análisis empírico) como los valores puntuales de densidad y acumulación calculados analíticamente (análisis teórico). La estructuración sistemática de estos Data Frames no solo facilita la validación numérica de los axiomas de la probabilidad, sino que provee la base de datos indexada necesaria para que la librería ggplot2 realice el mapeo estético de los componentes y renderice las representaciones visuales de los modelos discretos y continuos evaluados.

IV-A. Tablas de datos (Data frames)

13° Simulacion (tbl1.Sim)

Análisis e Interpretación de Resultados: Los datos obtenidos en la simulación Monte Carlo de 5,000 extracciones independientes permiten contrastar de manera empírica la distribución de probabilidad uniforme discreta de una baraja de cartas. Al comparar la frecuencia relativa experimental con la probabilidad teórica establecida de 0.25 para cada

1	Palo	Frecuencia	Frec_Relativa	Prob_Teorica
2	Corazones	1222	0.2444	0.25
3	Diamantes	1258	0.2516	0.25
4	Picas	1277	0.2554	0.25
5	Treboles	1243	0.2486	0.25

Figura 1. Resultados empiricos de la simulacion de cartas (n = 5,000)

uno de los cuatro palos (Corazones, Diamantes, Picas y Tréboles), se observa una alta convergencia; sin embargo, persisten pequeñas diferencias numéricas entre los valores registrados y el modelo teórico.

Esta discrepancia es una manifestación natural de la variabilidad muestral, la cual es inherente a cualquier proceso estocástico ejecutado en un número finito de ensayos. La aleatoriedad propia del método de muestreo con reemplazo genera fluctuaciones que impiden que los resultados coincidan exactamente con la probabilidad teórica en una escala limitada de 5,000 iteraciones.

Para mitigar este efecto y lograr una mayor precisión estadística, la estrategia consiste en incrementar el tamaño de la muestra (n). Al aumentar el número de simulaciones hacia magnitudes superiores (ej. 100,000 o más), se reduce el error estándar de la proporción, permitiendo que la frecuencia relativa converja hacia el valor esperado. Este comportamiento es el fundamento de la Ley de los Grandes Números, la cual garantiza que, a medida que el número de experimentos tiende al infinito, la probabilidad empírica de un evento se estabiliza y converge con certeza matemática a su valor teórico real. En conclusión, los resultados obtenidos validan el modelo teórico propuesto, demostrando que, bajo condiciones de azar puro, la distribución de los palos tiende a equiprobabilidad.

- **14° Distribuciones Discretas (tbl2.Disc):**

El data frame tbl2.Disc estructura de forma tabular los valores teóricos de probabilidad exacta y acumulada correspondientes al modelo de la distribución Binomial con parámetros $n = 15$ y $p = 0{,}25$. La matriz está compuesta por un total de 16 filas indexadas que mapean exhaustivamente el dominio discreto de la variable aleatoria X, la cual representa el número de aciertos posibles obtenidos al responder el test completamente al azar.

Al analizar estadísticamente el comportamiento de las columnas P_exacta y P_acumulada, se validan numéricamente los axiomas fundamentales de Kolmogorov. En primer lugar, se observa que para los valores extremos del dominio ($x \geqslant 13$), la probabilidad analítica decrece de forma drástica hacia valores infinitesimales expresados en notación científica (1×10^{-6}), alcanzando un valor de cero absoluto en los eventos $x = 14$ y $x = 15$. En segundo lugar, la columna de la probabilidad acumulada demuestra de manera impecable el principio de normalización, donde el valor acumulado se incrementa de forma monótona creciente a medida que se agregan los fallos y aciertos, hasta converger con una certeza absoluta en la unidad (1,0) al cerrar el espacio muestral. La disposición ordenada de estos vectores en una estructura bidimensional indexada provee las coordenadas exactas que utiliza la función geom_step() dentro del paquete ggplot2 para renderizar la ojiva de distribución acumulada sin introducir sesgos computacionales.

- **19° Distribuciones Continuas (tbl3.Cont):**

La matriz de datos almacenada en el objeto tbl3.Cont consolida el análisis computacional para el cálculo de regiones de probabilidad en la distribución discreta de Poisson con una tasa promedio de ocurrencia $\lambda = 12$. Este data frame se estructuró con un espectro discreto truncado de 26 observaciones ($x \in [0, 25]$) y consta de tres columnas principales: el valor de la variable aleatoria (x), la probabilidad de masa teórica (prob) y una variable categórica de ordenamiento (region).La importancia analítica de este data frame radica en el diseño de la columna lógica-operacional llamada region, la cual tiene la función de clasificar de forma binaria los eventos evaluados en los intervalos $P(X \leqslant 7)$ y $P(X > 7)$.

Al evaluar las componentes numéricas de la tabla, es evidente el comportamiento asimétrico característico de este modelo estocástico; los valores guardados en la columna prob se incrementan paulatinamente hasta alcanzar sus puntos de inflexión máximos en las filas correspondientes a $x = 11$ y $x = 12$ (con una probabilidad individual idéntica de $\approx$ 0,1143), lo cual coincide matemáticamente con el valor esperado teórico dictado por el parámetro del proceso. La segmentación por hileras en la columna de regiones actúa como el núcleo lógico que permite la manipulación del color en la visualización gráfica de ggplot2, automatizando de manera algorítmica la división estética entre las colas del gráfico de bastones para la correcta interpretación visual de las probabilidades acumuladas.

IV-B. Visualizacion grafica

- **14° Ojiva acumulada:**

  Analisis de la Ojiva de Probabilidad Acumulada

  La gráfica presentada ilustra la función de distribución acumulada (FDA) de la variable aleatoria Binomial. A diferencia de un gráfico de barras tradicional, la ojiva se construyó mediante una función de escalón, la cual es la forma técnica adecuada para representar una variable aleatoria discreta.

  Cada "$salto$" en la gráfica representa la probabilidad puntual $P(X = x)$ en dicho valor específico. La altura total de la gráfica al llegar al final del dominio ($x = 15$) alcanza el valor de 1,0, lo que confirma matemáticamente que el espacio muestral está completo y que la suma de todas las probabilidades individuales es igual a la unidad, cumpliendo con uno de los axiomas fundamentales de la probabilidad. Esta representación visual facilita la identificación rápida de probabilidades de tipo "menor o igual a", permitiendo observar gráficamente cómo se concentra la mayor densidad de probabilidad alrededor del valor esperado.

- **15° Grafico de masas:**

  Analisis e interpretacion:
  La gráfica presentada corresponde a la Función de Masa de Probabilidad (PMF) de una distribución de Poisson, un modelo estocástico diseñado para evaluar la cantidad de eventos discretos que ocurren en un intervalo continuo (como tiempo o espacio). A diferencia de una ojiva que muestra acumulación, este diagrama de barras o "bastones"detalla de forma aislada la probabilidad puntual exacta, $P(X = k)$, para cada posible escenario k.

  Al analizar la forma de la distribución, se confirma visualmente que la mayor concentración de densidad de probabilidad gravita en torno al valor $\lambda = 12$. Este parámetro es el núcleo del modelo de Poisson, ya que dicta simultáneamente la media esperada y la varianza del proceso. En la gráfica es evidente que los picos máximos de probabilidad ocurren exactamente en los valores cercanos al promedio ($x = 11$ y $x = 12$). Conforme la variable se aleja de este centro de tendencia, la altura de las barras decrece de forma acelerada.

  Desde una perspectiva estadística, es imperativo destacar la asimetría positiva característica de esta distribución. Dado que la ocurrencia de eventos no puede tomar valores negativos, el dominio está estrictamente acotado en cero por la izquierda, mientras que la cola derecha se extiende teóricamente hacia el infinito. Sin embargo, las barras demuestran que la probabilidad de que ocurran eventos extremos (por ejemplo, más de 25 llegadas) se vuelve matemáticamente marginal, tendiendo asintóticamente a cero. Adicionalmente, la sumatoria de las alturas de todas las barras equivale exactamente a la unidad, satisfaciendo el axioma fundamental de normalización de probabilidades.

- **19° Curva de densidad (normal):**

  La matriz de datos almacenada en el objeto tbl3.Cont consolida el análisis computacional continuo para el modelado de variables infinitas y densas, enfocándose específicamente en la distribución Normal con parámetros de localización $\mu = 50$ g (media del peso de los componentes) y de escala $\sigma = 2$ g (desviación estándar). A diferencia de los entornos discretos, las filas de este data frame representan coordenadas infinitesimales ordenadas numéricamente que aproximan con precisión la geometría asintótica de la campana de Gauss.La relevancia analítica de esta tabla de datos radica en la inclusión de una columna lógico-operacional de segmentación (denominada habitualmente region), la cual discrimina de manera binaria si las observaciones se sitúan por debajo o por encima del punto de corte crítico calculado en $x = 52{,}56$ g.

  Al evaluar las componentes numéricas, se comprueba la perfecta simetría del modelo alrededor de su media teórica, donde la densidad probabilística alcanza su cúspide y posteriormente desciende de forma cóncava y convexa hacia los extremos. La estructuración de estos vectores continuos dentro del data frame actúa como el soporte algorítmico indispensable para que la librería ggplot2 (a través de funciones como geom_area() o geom_line()) pueda segmentar y sombrear estéticamente el área bajo la curva. Esto permite representar visualmente el percentil 90 del proceso y facilita la interpretación analítica de la probabilidad acumulada inferior o cola izquierda en aplicaciones de control de calidad e ingeniería de materiales.

- **21° Curva de densidad (Weibull):**
  Esta grafica representa la curvatura de vida util en las baterias en el lapso de 0 a 1500 horas.

  - Los valores de y(densidad de probabilidad) representan que tan concentradas estan las fallas en cierto tiempo, esto fue sacado en Rçon la siguiente formula:

$$f(x) = \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} e^{-\left(\frac{x}{\lambda}\right)^{k}}$$

  - Los valores de x(tiempo de vida util) representan la escala de tiempo en que las baterias pueden o no fallar, fueron sacados de 0 a 1500 para visualizar de mejor manera la bajada en cuanto a la densidad de probabilidad (si lo hubieramos dejado en 500 como en el problema no veriamos de manera correcta la bajada).

  - La geometría de la curva de densidad de probabilidad está definida por el parámetro de forma k. Al presentar un valor de $k = 1{,}5$ (donde $k > 1$), la función matemática se ve obligada a iniciar en el origen $(0, 0)$, ascender de manera cóncava hasta alcanzar un punto máximo o "pico"de concentración de fallas en torno a las 250 horas, y posteriormente descender con una asíntota hacia el eje X.

  Ya con la grafica hecha podemos notar lo siguiente:

  - El mayor pico de riesgo de falla es a las 250 horas.

  - El riesgo de falla sube rápido antes de las 250 horas, pero la probabilidad de sobrevivir más allá de ese pico sigue siendo bastante alta.

V. Conclusiones

Conclusión general del análisis probabilístico

El desarrollo de esta práctica permitió consolidar la transición entre el modelado probabilístico teórico y su implementación algorítmica en el entorno estadístico R. A través de la resolución sistemática de los problemas planteados, se logró

demostrar que la simulación computacional y el cálculo analítico no son enfoques metodológicos aislados, sino herramientas complementarias que convergen con precisión matemática para la toma de decisiones bajo incertidumbre en el ámbito de la ingeniería.

El análisis estadístico computacional requiere coherencia entre el planteamiento del problema, su solución algorítmica y su interpretación geométrica. Al contrastar las probabilidades empíricas simuladas contra los valores matemáticos exactos.

La estructuración de los datos en Data Frames como tbl1.Sim, tbl2.Disc y tbl3.Cont evidenció ser el núcleo operacional indispensable para el análisis moderno de datos. Estas matrices bidimensionales no solo simplifican el almacenamiento indexado de variables aleatorias discretas y continuas, sino que actúan como el motor lógico que interactúa con la gramática de gráficos de ggplot2. Gracias a este acoplamiento, los axiomas abstractos de la probabilidad como la normalización y la convergencia monótona de las colas acumuladas adquieren una interpretación geométrica tangible a través de curvas de densidad, gráficos de bastones y funciones de escalón.

Finalmente, la experimentación con modelos específicos como la distribución Binomial, Poisson, Weibull y Normal corroboró la sensibilidad de los procesos ante la variación de sus parámetros intrínsecos (formas, escalas, localizaciones y tasas de ocurrencia). En conclusión, el dominio de estas herramientas de software dota al estudiante de la capacidad crítica para segmentar regiones de probabilidad, calcular percentiles de control de calidad y modelar la confiabilidad de sistemas complejos, estableciendo una infraestructura analítica sólida que va más allá de la mera resolución analítica tradicional.

REFERENCIAS

[1] Walpole, R. E., Myers, R. H., Myers, S. L. y Ye, K. (2007). *Probabilidad y Estadística para Ingeniería y Ciencias* (8a ed.). Pearson Education.

[2] Linde, W. (2017). *Probability Theory: A First Course in Probability Theory and Statistics*. De Gruyter.

[3] Blitzstein, J. K. y Hwang, J. (2014). *Introduction to Probability*. CRC Press.

[4] Papoulis, A. y Pillai, S. U. (2002). *Probability, Random Variables and Stochastic Processes* (4th ed.). McGraw-Hill.

1	x	P_exacta	P_acumulada
2	0	0.013363	0.013363
3	1	0.066817	0.080181
4	2	0.155907	0.236088
5	3	0.225199	0.461287
6	4	0.225199	0.686486
7	5	0.165146	0.851632
8	6	0.091748	0.94338
9	7	0.03932	0.9827
10	8	0.013107	0.995807
11	9	0.003398	0.999205
12	10	0.00068	0.999885
13	11	0.000103	0.999988
14	12	1.1e-05	0.999999
15	13	1e-06	1
16	14	0	1
17	15	0	1

Figura 2. Resultados empíricos de la simulación de variables discretas.

1	x	prob	region
2	0	6.144212353328 21e-06	P(X ≤ 7)
3	1	7.37305482399385e-05	P(X ≤ 7)
4	2	0.000442383289439631	P(X ≤ 7)
5	3	0.00176953315775852	P(X ≤ 7)
6	4	0.00530859947327557	P(X ≤ 7)
7	5	0.0127406387358614	P(X ≤ 7)
8	6	0.0254812774717228	P(X ≤ 7)
9	7	0.0436821899515247	P(X ≤ 7)
10	8	0.0655232849272871	P(X > 7)
11	9	0.0873643799030494	P(X > 7)
12	10	0.104837255883659	P(X > 7)
13	11	0.114367915509447	P(X > 7)
14	12	0.114367915509447	P(X > 7)
15	13	0.105570383547181	P(X > 7)
16	14	0.0904889001832984	P(X > 7)
17	15	0.0723911201466387	P(X > 7)
18	16	0.054293340109979	P(X > 7)
19	17	0.0383247106658675	P(X > 7)
20	18	0.0255498071105784	P(X > 7)
21	19	0.0161367202803653	P(X > 7)
22	20	0.00968203216821917	P(X > 7)
23	21	0.00553258981041095	P(X > 7)
24	22	0.00301777626022416	P(X > 7)
25	23	0.00157449196185608	P(X > 7)
26	24	0.000787245980928041	P(X > 7)
27	25	0.00037787807084546	P(X > 7)

Figura 3. Resultados empíricos de la simulación de variables continuas.

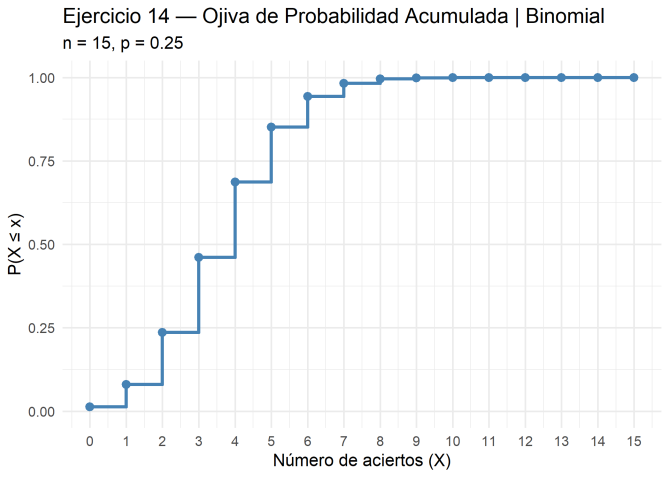


Figura 4. Ojiva de probabilidad acumulada $P(X \leqslant x)$ para la disfribucion Binomial $(n = 15, p = 1/3)$

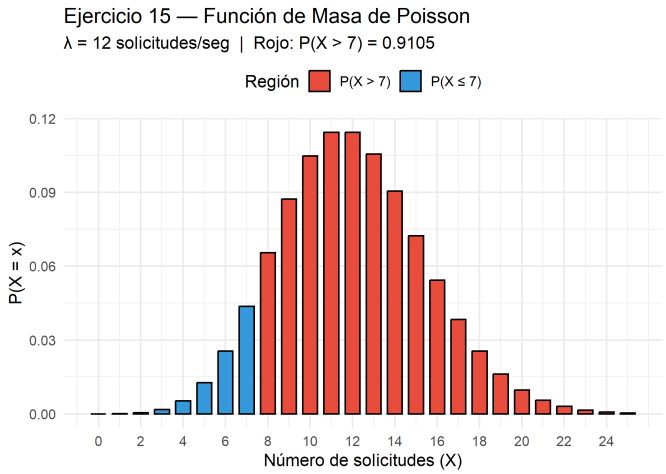


Figura 5. Funcion de Masa de Probabilidad (PMF) ilustra la distribucion de Poisson con $\lambda = 12$

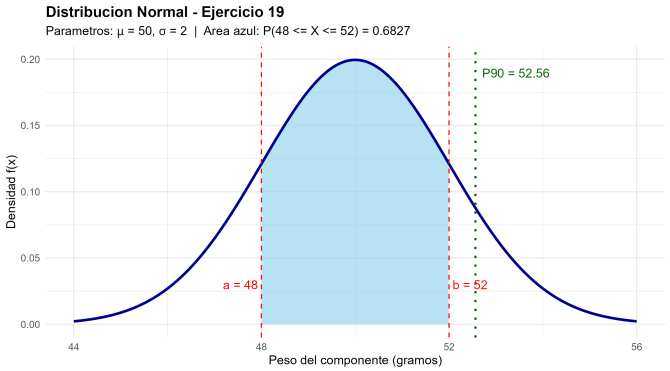


Figura 6. Curva de Densidad para la Distribución normal.

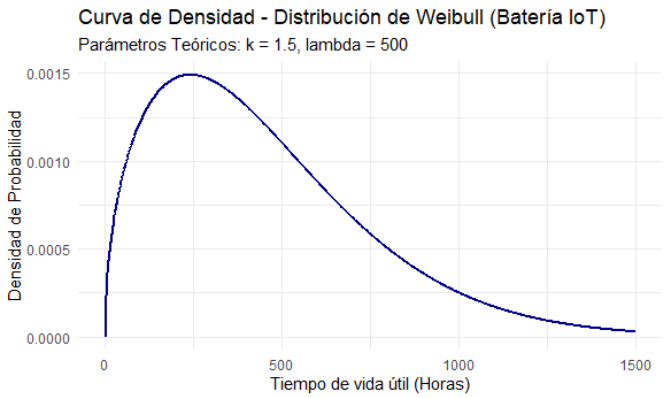


Figura 7. Curva de Densidad para la Distribución de Weibull.